

**LAPORAN TUGAS**  
**“ANALISIS KESEHATAN JANIN MENGGUNAKAN**  
**METODE PADA DATA MINING (ORANGE)”**

**Dosen Pengampu : Eka Mala Sari Rochman, S.Kom.M.Kom**



**Disusun Oleh :**  
**MUHAMMAD MUQTAFIN NUHA**  
**210411100218**

**PRODI TEKNIK INFORMATIKA JURUSAN TEKNIK**  
**INFORMATIKA FAKULTAS TEKNIK**  
**UNIVERSITAS TRUNOJOYO MADURA**  
**2023**

## **KATA PENGANTAR**

Kepada Tuhan Yang Maha Esa, saya haturkan puji syukur yang dalam atas segala berkat-Nya, yang telah mengizinkan saya menyelesaikan laporan ini dengan baik.

Saya juga ingin mengucapkan rasa terima kasih yang mendalam kepada semua pihak yang telah turut serta dalam proses penyusunan tugas ini. Terutama, saya ingin mengungkapkan rasa terima kasih kepada dosen pembimbing saya, yang telah memberikan bimbingan, arahan, dan dukungan yang sangat berarti dalam perjalanan saya dalam menyusun laporan ini.

Laporan ini berjudul “Analisis Kesehatan Janin Menggunakan Metode Data Mining” dan disusun sebagai salah satu syarat untuk menyelesaikan Ujian Tengah Semester mata kuliah Proyek Sains Data.

Saya berharap bahwa hasil penelitian dan pembelajaran yang terkandung dalam laporan ini dapat memberikan manfaat yang nyata bagi orang-orang yang membacanya. Saya sangat menghargai segala kritik dan saran yang dapat membantu memperbaiki konsep penulisan dan penyusunan laporan ini.

Terima kasih atas perhatian dan dukungan semua pihak dalam penyusunan laporan ini. Semoga laporan ini menjadi kontribusi yang berarti dalam bidang sains data dan Kesehatan janin.

**Bangkalan, 11 Oktober 2023**

**Penyusun**

**Muhammad Muqtafin Nuha**

## **ABSTRAK**

## DAFTAR ISI

<i>ABSTRAK</i> .....	3
<i>BAB I PENDAHULUAN</i> .....	6
1.1 Latar Belakang.....	6
1.2 Rumusan Masalah.....	7
1.3 Tujuan .....	7
1.4 Manfaat .....	8
1.5 Batasan Masalah .....	8
<i>BAB II TINJAUAN PUSTAKA</i> .....	9
2.1 Landasan Teori.....	9
2.1.1 Fetal Health.....	9
2.1.2 Data .....	10
2.1.3 Data Mining (Penambangan Data).....	12
2.1.4 Klasifikasi .....	14
2.1.5 <i>Decision Tree</i> (Pohon Keputusan) .....	14
2.1.6 Algoritma C4.5.....	15
2.1.7 Naive Bayes .....	17
2.2 Penelitian Sebelumnya.....	18
2.3 Evaluasi Pengukuran.....	18
2.3.2 Akurasi .....	19
2.3.3 Precision.....	20
2.3.4 Recall .....	20
2.3.5 F1-Score.....	20
<i>BAB III METODOLOGI PENELITIAN</i> .....	22
3.1 Tujuan Penelitian .....	22
3.2 Tempat dan Waktu Penelitian.....	22
3.3 Populasi dan Teknik Pengambilan Sampel .....	22

3.3.1 Populasi.....	22
3.3.2 Sampel.....	22
3.4 Teknik Pengumpulan Data.....	23
<i>BAB IV HASIL &amp; PEMBAHASAN.....</i>	<i>24</i>
4.1 Data collection .....	24
4.2 Data preprocessing.....	26
4.2.1 <i>Features Statistic</i> .....	26
4.2.2 Seleksi Fitur dan target .....	28
4.2.3 Edit Domain .....	28
4.3 Splitting data .....	29
4.3.1 Splitting data training 60% dan testing 40%.....	29
4.3.2 Splitting data training 70% dan testing 30%.....	31
4.3.3 Splitting data training 80% dan testing 20%.....	32
4.3.4 Splitting data training 90% dan testing 10%.....	34
4.4 Penerapan Algoritma Naïve Bayes dan Decision Tree .....	35
4.5 Evaluasi data dengan Confussion Matrix .....	44
<i>BAB V PENUTUP.....</i>	<i>47</i>
5.1 Kesimpulan .....	47
5.2 Saran .....	47

## **BAB I PENDAHULUAN**

### **1.1 Latar Belakang**

Kehamilan seorang wanita adalah masa yang krusial dan sulit dalam hidupnya. Seorang Wanita akan mengalami perubahan fisik dan psikologis selama kehamilan sebagai akibat dari ketidakseimbangan hormone progesterone dan estrogen [1]. Memiliki seorang buah hati kondisi sehat merupakan salah satu impian besar bagi seorang ibu. Kondisi ibu yang tidak sehat dapat mengancam Kesehatan janin di dalam Rahim. Sebaliknya, janin yang tidak sehat dapat mengancam Kesehatan ibu yang sedang mengandung, sehingga sang ibu memiliki kemungkinan mengalami keguguran, bahkan kematian pada saat melahirkan [2].

Masa kehamilan dan masa-masa persalinan adalah merupakan suatu rentang waktu yang kritis bagi para ibu-ibu hamil karena segala kemungkinan dapat terjadi sebelum berakhir dengan selamat atau dengan kematian [3]. Asuhan antenatal yang kurang optimal, seperti kurangnya pemahaman ibu mengenai pentingnya pemeriksaan ANC sehingga bisa menumbuhkan adanya dampak komplikasi pada saat kehamilan, persalinan, nifas bayi yang baru lahir, serta keluarga berencana, oleh karena itu, pemeriksaan merupakan layanan yang sangat penting bagi petugas Kesehatan. Dengan cara ini pertumbuhan dan perkembangan penyakit dapat dipantau setiap saat [4].

Data *World Health Organization* (WHO) terdapat dari profil angka kejadian KJDK di Indonesia, pada tahun 2015 angka kematian janin atau keguguran di dunia diperkirakan sekitar 3,82 – 22,14 juta jiwa. Suatu kematian janin di dalam sebuah kandungan ibu merupakan masalah perinatal, indikator Kesehatan dan masa yang sangat sensitive dalam kaitannya dengan Kesehatan ibu dan anak, kematian perinatal mendata sekitar 77% dari kematian neonatal, dimana kematian neonatal 58% dari total kematian janin bahkan bayi [4].

Metode Cardiotography (CTG) proses pemeriksaan Kesehatan janin pada ibu yang sedang hamil. CTG adalah alat untuk memantau aktivitas denyut jantung janin, kontraksi Rahim dan beberapa elemen yang dibutuhkan saat janin berada di dalam kandungan. CTG merupakan metode terbuka untuk pasien yang dianjurkan dokter berdasarkan indikasi medis secara berkala saat mengalami kondisi seperti demam tinggi, hipertensi atau diabetes. Hasil laboratorium akan didiagnosa oleh dokter untuk mengevaluasi kondisi janin apakah dalam keadaan sehat baik sebelum dan selama persalinan. Misalnya, Ketika Kesehatan janin dari

seorang ibu hamil mengalami perubahan pada denyut jantung maupun kontraksi Rahim pada ibu hamil, dengan menggunakan alat CTG petugas (dokter dan bidan) dapat mendeteksi dini kesehatan janin. Proses pemantauan Kesehatan janin, serta kewaspadaan dan pada kondisi tertentu melakukan Tindakan medis menghindari keguguran, bahkan dapat mengurangi resiko kematian bagi ibu dan janin [5].

Namun hasil uji laboratorium dari CTG terhadap Kesehatan janin memerlukan seorang pakar Kesehatan janin. Pemanfaatan system pendukung keputusan terhadap hasil uji CTG, maka hasil pemeriksaan CTG dapat dievaluasi secara system terkait kondisi janin dan merekomendasikan secara dini dari system pendukung keputusan terhadap kondisi Kesehatan janin [2].

Pada penelitian ini bertujuan untuk mendiagnosa suatu ketidakpastian terkait kondisi Kesehatan janin yang dikandung seorang ibu hamil memanfaatkan Cardiotography menggunakan algoritma pada data mining seperti, Naïve Bayes, Decision Tree, dan algoritma lainnya untuk meminimalisi tingkat keguguran dan resiko kematian janin yang terjadi di dunia terutama di Indonesia.

## **1.2 Rumusan Masalah**

Rumusan masalah dalam penelitian ini berdasarkan latar belakang adalah, sebagai berikut:

- a. Bagaimana distribusi Kesehatan janin dengan menggunakan data Fetal Health Classification?
- b. Bagaimana cara menganalisis data Kesehatan janin dengan menggunakan data Fetal Health Classification?
- c. Bagaimana cara melakukan klasifikasi Kesehatan janin dengan menggunakan metode pada data mining untuk mendapatkan nilai Accuracy, Precision dan Recall?
- d. Bagaimana menentukan metode terbaik untuk diagnosis Kesehatan janin dengan menggunakan metode pada data mining?

## **1.3 Tujuan**

Tujuan yang ingin dicapai dari penelitian ini, sebagai berikut:

- a. Mengetahui distribusi Kesehatan janin pada data Fetal Health Classification.

- b. Mengetahui hasil analisis Kesehatan janin pada data Fetal Health Classification.
- c. Mengetahui nilai Accuracy, Precision dan Recall pada setiap algoritma data mining.
- d. Mengetahui metode terbaik untuk mendiagnosis Kesehatan janin.

#### **1.4 Manfaat**

Penelitian ini diharapkan dapat memiliki beberapa manfaat, antara lain:

- a. Penelitian ini diharapkan dapat membantu meningkatkan pemahaman tentang kondisi Kesehatan janin pada ibu hamil. Informasi ini dapat berguna bagi ibu hamiln keluarga, serta tenaga medis yang merawat ibu hamil.
- b. Dengan menggunakan algoritma data mining, diharapkan penelitian ini dapat membantu mendeteksi dini masalah Kesehatan janin, sehingga tindakan medis dapat diambil untuk mengurangi risiko keguguran dan kematian janin maupun ibu hamil.
- c. Hasil penelitian ini diharapkan dapat digunakan sebagai panduan bagi tenaga medis dalam memberikan pelayanan antenatal yang lebih baik kepada ibu hamil
- d. Penelitian ini diharapkan dapat memberikan kontribusi pada pengembangan teknologi dalam dunia Kesehatan.

#### **1.5 Batasan Masalah**

- a. Penelitian ini terbatas pada data yang tersedia dalam dataset Fetal Health Classification yang diambil dari Kaggle. Informasi yang diambil dari data tersebut menjadi dasar analisis Kesehatan janin.
- b. Penelitian ini akan menggunakan beberapa algoritma data mining seperti Naïve Bayes, Decision Tree, dan algoritma lainnya untuk menganalisis data Kesehatan janin. Namun, penelitian tidak akan mencakup semua algoritma yang mungkin ada.
- c. Hasil dari analisis data mining adalah rekomendasi dan prediksi.
- d. Penelitian ini akan mematuhi etika dan privasi data pasien. Data yang digunakan dalam penelitian harus diolah dengan memperhatikan kerahasiaan data pasien dan peraturan yang berlaku.



## **BAB II TINJAUAN PUSTAKA**

### **2.1 Landasan Teori**

#### **2.1.1 Fetal Health**

Kesehatan janin adalah gambaran mengenai kondisi Kesehatan janin yang dapat diperoleh melalui berbagai metode pemantauan, termasuk medis dan penggunaan teknologi seperti Cardiotography (CTG). Pemantauan Kesehatan janin adalah Langkah penting untuk mendeteksi dini masalah Kesehatan yang mungkin timbul selama kehamilan. Pemantauan ini melibatkan pengamatan denyut jantung janin, kontraksi Rahim dan parameter lain yang dapat memberikan informasi tentang perkembangan janin.

Pentingnya pemantauan Kesehatan janin terutama berkaitan dengan risiko komplikasi yang dapat memengaruhi baik ibu maupun janin. Ketidakseimbangan hormone, penyakit ibu, dan factor lingkungan dapat memengaruhi Kesehatan janin. Pemantauan Kesehatan janin dapat membantu dalam mendeteksi kondisi seperti asfiksia janin, gangguan pertumbuhan janin, dan masalah jantung janin yang dapat mengancam Kesehatan dan kelangsungan hidup janin.

Metode pemantauan Kesehatan janin, seperti CTG, telah menjadi standar dalam perawatan prenatal. CTG memungkinkan tenaga medis untuk memantau denyut jantung janin dan kontraksi Rahim secara real-time. Perubahan dalam pola denyut jantung janin dapat memberikan petunjuk awal tentang masalah Kesehatan janin. Misalnya, penurunan denyut jantung yang signifikan dapat mengindikasikan kekurangan oksigen pada janin.

Selain alat-alat pemantauan, teknologi data mining dan algoritma dapat digunakan untuk menganalisis data Kesehatan janin dan membuat prediksi tentang risiko Kesehatan janin. Ini adalah pendekatan yang berkembang dalam perawatan prenatal yang bertujuan untuk meningkatkan deteksi dini masalah Kesehatan janin dan mengurangi risiko keguguran serta kematian janin.

Secara keseluruhan, pemantauan Kesehatan janin adalah Langkah penting dalam perawatan kehamilan. Pentingnya pemantauan ini dalam mengidentifikasi masalah Kesehatan janin dan merencanakan Tindakan medis yang sesuai telah membantu mengurangi angka kematian janin dan meningkatkan Kesehatan ibu hamil. Teknologi

seperti CTG dan algoritma data mining memiliki peran penting dalam upaya ini untuk meningkatkan pemantauan dan diagnosis Kesehatan janin..

### 2.1.2 Data


Dalam penelitian ini terdapat 21 fitur yang digunakan dan 1 buah label sebagai target, adapun fitur-fitur tersebut yakni *Baseline value*, *Accelerations*, *Fetal movement*, *Uterine contractions*, *Light decelerations*, *Severe decelerations*, *Prolongued decelerations*, *Abnormal short term variability*, *Mean value of short term variability*, *Percentage of time width abnormal long term variability*, *Mean value of long term variability*, *Histogram width*, *Histogram min*, *Histogram max*, *Histogram number of peaks*, *Histogram number of zeroes*, *Histogram mode*, *Histogram mean*, *Histogram median*, *Histogram variance*, *Histogram tendency*, *Fetal health*. berikut adalah penjelasan singkat tentang setiap atribut yang terkait dengan *Fetal Health*:

1. **Atribut *baseline\_value*** berisi data denyut jantung janin atau FHR (*Fetal Health Rate*) dengan satuan numerik. FHR pada janin normal umumnya berkisar antara 110 sampai dengan 160. Sedangkan FHR dibawah 110 diklasifikasikan *Fetal Bradycardia*. Jika di atas 160 diklasifikasikan *Fetal Tachcardia* [6]. *Fetal Tachcardia* adalah peningkatan detak jantung janin yang tidak normal. *Fetal Bradycardia* adalah rendahnya detak jantung janin secara tidak normal.
2. **Atribut *accelerations*** berisi data jumlah akselerasi janin per detik dengan satuan numerik. Pada kasus ini, atribut *accelerations* akan dibagi menjadi 2 kategori, antara lain bernilai *True* jika janin melakukan akselerasi lebih dari 0 detik, dan *False* jika janin tidak melakukan akselerasi saat dilakukan *Cardiotocography*.
3. **Atribut *fetal\_movement*** berisi data jumlah Gerakan janin per detik dengan satuan numerik. Pada kasus ini, atribut *fetal\_movement* akan dibagi menjadi 2 kategori, bernilai *True* jika janin melakukan pergerakan lebih dari 0 detik, dan *False* jika janin tidak melakukan pergerakan saat pengujian *Cardiotocography*.
4. **Atribut *uterine\_contractions*** berisi data jumlah kontraksi uterus per detik dengan satuan numerik. Atribut *uterine\_contractions* dibagi menjadi 2 kategori, antara lain bernilai *True* jika terdapat kontraksi *uterine* pada janin lebih dari 0 detik, *False* jika janin tidak terdapat kontraksi *uterine* saat uji *Cardiotocography*.

5. **Atribut light\_decelerations** berisi data jumlah LD per detik dengan satuan numerik. Pada atribut dibagi 2 kategori, antara lain bernilai *True* jika terdapat tingkat deselerasi ringan pada janin lebih dari 0 detik, *False* jika janin tidak terdapat tingkat deselerasi ringan saat dilakukan *Cardiotocography*.
6. **Atribut severe\_decelerations** berisi data jumlah SD per detik dengan satuan numerik. Atribut terdiri dari 2 kategori, antara lain bernilai *True* jika terdapat tingkat deselerasi yang berat pada janin lebih dari 0 detik, dan *False* jika janin tidak terdapat tingkat deselerasi yang berat saat dilakukan *Cardiotocography*.
7. **Atribut prolonged\_decelerations** berisi data jumlah PD per detik dengan satuan numerik dan dibagi menjadi 2 kategori, bernilai *True* jika terdapat tingkat deselerasi yang berkepanjangan pada janin lebih dari 0 detik, dan *False* jika janin tidak terdapat tingkat deselerasi yang berkepanjangan saat dilakukan *Cardiotocography*.
8. **Atribut abnormal\_short\_term\_variability** berisi data persentase waktu dengan variabilitas jangka Panjang yang abnormal dalam satuan numerik.
9. **Atribut mean\_value\_of\_short\_term\_variability** berisi data rata-rata variabilitas jangka pendek dalam satuan numerik.
10. **Atribut percentage\_of\_time\_with\_abnormal\_long\_term\_variability** berisi data persentase variabilitas jangka Panjang dalam satuan numerik.
11. **Atribut mean\_value\_of\_long\_term\_variability** berisi data nilai rata-rata variabilitas jangka Panjang dalam satuan numerik.
12. **Atribut histogram\_width** berisi data lebar histogram yang dibuat menggunakan semua nilai dari sebuah record dalam satuan numerik.
13. **Atribut histogram\_min** berisi data nilai minimum histogram dalam satuan numerik.
14. **Atribut histogram\_max** berisi data nilai maksimum histogram dalam satuan numerik.
15. **Atribut histogram\_number\_of\_peaks** berisi tentang data jumlah puncak dalam pengujian histogram dalam satuan numerik.
16. **Atribut histogram\_number\_of\_zeroes** berisi tentang data jumlah angka nol dalam pengujian histogram dalam satuan numerik.

17. **Atribut histogram\_mode** berisi tentang data mode histogram dalam satuan numerik.
18. **Atribut histogram\_mean** berisi tentang data rata-rata histogram dalam satuan numerik.
19. **Atribut histogram\_median** berisi tentang data nilai median histogram dalam satuan numerik.
20. **Atribut histogram\_variance** berisi tentang data perbedaan histogram dalam satuan numerik.
21. **Atribut histogram\_tendency** berisi tentang data kecenderungan histogram dalam satuan numerik.
22. **Atribut fetal\_health** berisi tentang data Kesehatan janin dalam satuan numerik.

Data mining merupakan proses untuk menemukan pola yang menarik dan pengetahuan dari sejumlah besar data (Han et al., 2012). Sumber data dapat berupa basis data, data warehouse, web, gudang informasi lain dan data yang berasal dari system yang dinamis. Selain itu penambahan data juga merupakan proses untuk mendapatkan informasi yang berguna dari Gudang basis data yang besar (Tan et al., 2006).



1. *Data Cleaning* (Pembersihan Data)

*Data cleaning* (Pembersihan Data) adalah proses yang dilakukan untuk menghilangkan *noise* pada data yang tidak konsisten atau bisa disebut tidak relevan.

2. *Data Integration* (Integrasi Data)

Integrasi data merupakan proses penggabungan data dari berbagai *database* sehingga menjadi satu *database* baru.

3. *Data Selection* (Seleksi Data)

Tidak semua data yang terdapat dalam *database* akan dipakai, karena hanya data yang sesuai saja yang akan dianalisis dan diambil dari *database*.

4. *Data Transformation* (Transformasi Data)

Transformasi data merupakan proses pengubahan data dan penggabungan data ke dalam format tertentu. Misalnya metode standar seperti analisis asosiasi dan *clustering* hanya bisa menerima input data yang bersifat kategorikal.

5. Proses Mining

Proses *mining* dapat disebut juga sebagai proses penambangan data. Proses *mining* merupakan proses utama yang menggunakan metode untuk menemukan pengetahuan berharga yang tersembunyi dari data.

6. *Pattern Evaluation* (Evaluasi Pola)<sup>75</sup>

Evaluasi pola bertugas untuk mengidentifikasi pola-pola yang menarik ke dalam *knowledge based* yang ditemukan. Pada tahap ini dihasilkan pola-pola yang has dari model klasifikasi yang dievaluasi untuk menilai apakah hipotesa yang ada memang tercapai.

7. *Knowledge Presentation* (Presentasi Pengetahuan)

Presentasi pengetahuan merupakan visualisasi dan penyajian pengetahuan mengenai metode yang digunakan untuk memperoleh pengetahuan atau informasi yang telah digali oleh pengguna. Tahap terakhir proses *data mining* adalah memformulasikan keputusan dari hasil analisis yang didapat.

#### 2.1.4 Klasifikasi

Klasifikasi adalah suatu *fungsi* *data mining* yang menghasilkan model untuk memprediksi kelas atau kategori dari objek-objek didalam basis data. Klasifikasi merupakan proses yang terdiri dari dua tahap, yaitu tahap pembelajaran dan tahap pengklasifikasian.

Pada tahap pembelajaran, sebuah algoritma klasifikasi akan membangun sebuah model klasifikasi dengan cara menganalisis training data. Tahap pembelajaran dapat juga dipandang sebagai tahap pembentukan fungsi atau pemetaan  $Y=F(X)$  dimana Y adalah kelas hasil prediksi dan X adalah *tuple* yang ingin diprediksi kelasnya. Selanjutnya pada tahap pengklasifikasian, model yang telah dihasilkan akan digunakan untuk melakukan pengklasifikasian.

Menurut Herman Aldino, Naam, Julfriadi (2012), klasifikasi adalah proses pencarian sekumpulan model yang menggambarkan dan membedakan kelas data dengan tujuan agar model tersebut dapat digunakan untuk memprediksi kelas dari suatu obyek yang belum diketahui kelasnya.

#### 2.1.5 Decision Tree (Pohon Keputusan)

Pohon (*tree*) adalah sebuah struktur data yang terdiri dari simpul (*node*) dan rusuk (*edge*). Simpul pada sebuah pohon dibedakan menjadi tiga, yaitu simpul akar (*root node*), simpul percabangan/internal (*branch/internal node*) dan simpul daun (*leaf node*) [8].


Pohon keputusan merupakan representasi sederhana dari Teknik klasifikasi untuk sejumlah kelas berhingga, dimana simpul internal maupun simpul akar ditandai dengan nama atribut, rusuk-rusuknya diberi label nilai atribut yang mungkin dan simpul daun ditandai dengan kelas-kelas yang berbeda [8].



Gambar 2 Konsep Pohon Keputusan

Proses pada pohon keputusan adalah mengubah bentuk data (table) menjadi model pohon, mengubah model pohon menjadi *rule*, dan menyederhanakan *rule*. Manfaat utama dari penggunaan pohon keputusan adalah kemampuannya untuk *membreakdown* proses pengambilan keputusan yang *kompleks* menjadi lebih simple sehingga pengambilan keputusan akan lebih menginterpretasikan solusi dari permasalahan. Pohon keputusan juga berguna untuk mengeksplorasi data, menemukan hubungan tersembunyi antara sejumlah calon variabel input dengan sebuah variabel target.

Pohon keputusan merupakan himpunan aturan *IF...THEN*. Setiap *path* dalam *tree* dihubungkan dengan sebuah aturan, dimana premis terdiri atas sekumpulan *node-node* yang ditemui, dan kesimpulan dari aturan terdiri atas kelas yang terhubung dengan *leaf* dari *path* [9].



Gambar 3 Konsep Dasar Pohon Keputusan

Bagian awal dari pohon keputusan ini adalah titik akar (*root*), sedangkan setiap cabang dari pohon keputusan merupakan pembagian berdasarkan hasil uji, dan titik akhir (*leaf*) merupakan pembagian kelas yang dihasilkan.

#### 2.1.6 Algoritma C4.5

Menurut Luthfi (2009), algoritma C4.5 adalah algoritma klasifikasi data dengan teknik pohon keputusan yang memiliki kelebihan-kelebihan. Kelebihan ini misalnya dapat mengolah data numerik (*kontinyu*) dan *diskret*, dapat menangani nilai atribut yang hilang,

menghasilkan aturan-aturan yang mudah diinterpretasikan dan tercepat diantara algoritma-algoritma yang lain.

Keakuratan prediksi yaitu kemampuan model untuk dapat memprediksi label kelas terhadap data baru atau yang belum diketahui sebelumnya dengan baik. Dalam hal ini kecepatan atau efisiensi waktu komputasi yang diperlukan untuk membuat dan menggunakan model. Kemampuan model untuk memprediksi dengan benar walaupun data ada nilai dari atribut yang hilang. Dan juga skalabilitas yaitu kemampuan untuk membangun model secara *efisien* untuk data berjumlah besar (aspek ini akan mendapatkan penekanan). Terakhir *interpretabilitas* yaitu model yang dihasilkan mudah dipahami.

Dalam algoritma C4.5 untuk membangun pohon keputusan hal pertama yang dilakukan yaitu memilih atribut sebagai akar. Kemudian dibuat cabang untuk tiap-tiap nilai didalam akar tersebut. Langkah berikutnya yaitu membagi kasus dalam cabang. Kemudian ulangi proses untuk setiap cabang sampai semua kasus pada cabang memiliki kelas yang sama.

Menurut Luthfi (2009), untuk memilih atribut dengan akar, didasarkan pada nilai *gain* tertinggi dari atribut-atribut yang ada. Untuk menghitung gain digunakan rumus seperti tertera dalam persamaan 1 berikut:

$$\text{Gain}(S, A) = \text{Entropy}(S) - \sum_{i=1}^n \frac{|S_i|}{|S|} * \text{Entropy}(S_i) \quad (1)$$

Keterangan:

$S$  : Himpunan kasus

$A$  : Atribut

$n$  : Jumlah partisi atribut A

$|S_i|$  : Jumlah kasus pada partisi ke-i

$|S|$  : Jumlah kasus dalam S

sehingga akan diperoleh nilai gain dari atribut yang paling tertinggi. Gain adalah salah satu *atribut selection measure* yang digunakan untuk memilih *test attribute* tiap *node* pada *tree*. Atribut dengan *information gain* tertinggi dipilih sebagai *test attribute* dari suatu *node*.

Sementara itu, penghitungan nilai entropi dapat dilihat pada persamaan 2 berikut:



$$\text{Entropy}(S) = \sum_{i=1}^n - p_i * \log_2 p_i \quad (2)$$

Keterangan:

- $S$  : Himpunan kasus
- $A$  : Atribut
- $n$  : Jumlah partisi atribut  $S$
- $p_i$  : Proporsi dari  $S_i$  terhadap  $S$

### 2.1.7 Naive Bayes

Naive Bayes merupakan sebuah metode klasifikasi yang berakar pada Teorema Bayes. Metode pengklasifikasian dengan menggunakan metode probabilitas dan statistik yang dikemukakan oleh ilmuwan Inggris Thomas Bayes. Ciri utama dari Naive Bayes Classifier adalah asumsi yang sangat kuat akan independensi dari masing-masing kondisi atau kejadian. Naive Bayes Algorithm sangat berguna untuk pembelajaran algoritma, pengetahuan masa lalu dan pengamatan data yang bisa digabungkan, ini dapat membantu dalam memberikan perspektif yang bermanfaat untuk memahami dan juga mengevaluasi banyak pembelajaran. Ini membantu menentukan probabilitas yang tepat untuk hipotesis dan juga kuat terhadap noise pada data input (Parveen & Pandey, 2017). Naive Bayes Classifier menggunakan data yang sudah ada yang bernama data training yang digunakan untuk membentuk sebuah model classifier. Model ini merupakan representasi pengetahuan yang akan digunakan untuk prediksi kelas data baru yang belum pernah ada. Kemudian membutuhkan data latih yang bernama data testing yang digunakan untuk mengukur sejauh mana classifier berhasil melakukan klasifikasi dengan benar. Kemudian rumus dasar dari Naive Bayes yang digunakan dapat dilihat pada persamaan 3.

$$P(H_i | X) = \frac{P(X | H_i)P(H_i)}{P(X)} \quad (3)$$

Keterangan:

- $X$  : Kriteria suatu kasus berdasarkan masukan
- $H_i$  : Kelas solusi pola ke- $i$ , dimana  $i$  adalah jumlah label kelas
- $P(H_i | X)$  : Probabilitas kemunculan label kelas  $H_i$  dengan kriteria masukan  $X$

$P(X | H_i)$  : Probabilitas kriteria masukan X dengan label kelas  $H_i$   
 $P(H_i)$  Probabilitas label kelas  $H_i$

## 2.2 Penelitian Sebelumnya

*Tabel 1 Penelitian Sebelumnya*

Peneliti, Tahun	Judul	Permasalahan	Metode	Hasil
Indah Sulihati, Abdul Syukur, Aris Marjuni (2022)	Deteksi Kesehatan Janin Menggunakan Decision Tree dan Feature Forward Selection	Kurangnya kesadaran tentang <i>Antenatal Care</i> (ANC) dan asuhan antenatal yang kurang optimal, ketidakakuratan diagnosis penyakit, tingginya angka kematian janin dan keguguran, serta tantangan dalam prediksi kelahiran prematur.	<i>Decision Tree</i> dan <i>Feature Forward Selection</i>	Pada algoritma <i>Decision Tree</i> didapatkan hasil akurasi sebesar 89.84%.  Sedangkan <i>Feature Forward Selection</i> didapatkan hasil akurasi sebesar 91.06%

## 2.3 Evaluasi Pengukuran

*Confusion Matrix* adalah table yang mampu menggambarkan atau mendeskripsikan suatu kinerja dari sebuah algoritma secara terperinci dan detail. Pada *Confusion Matrix* setiap baris menjelaskan class actual dari masing-masing data, sedangkan setiap kolom pada *Confusion Matrix* menjelaskan kelas prediksi dari data begitu pula sebaliknya.

Tabel 2 Confusion Matrix

	<b>Predicted Negative</b>	<b>Predicted Positive</b>
<b>Actual Negative</b>	True Negative (TN)	False Positive (FP)
<b>Actual Positive</b>	False Negative (FN)	True Positive (TP)

1. *True Positive* (TP) menunjukkan jumlah sampel positif yang diklasifikasikan dengan benar.
2. *True Negative* (TN) menunjukkan jumlah sampel negatif yang diklasifikasikan dengan benar.
3. *False Positive* (FP) menunjukkan jumlah sampel yang salah diklasifikasikan sebagai positif.
4. *False Negative* (FN) menunjukkan jumlah sampel yang salah diklasifikasikan sebagai negatif.

### 2.3.2 Akurasi

Akurasi (ACC). Akurasi adalah rasio antara sampel yang diklasifikasikan dengan benar dan jumlah total sampel dalam dataset evaluasi. Metrik ini adalah salah satu yang paling umum digunakan dalam aplikasi ML dalam kedokteran, tetapi juga dikenal menyesatkan dalam kasus proporsi kelas yang berbeda karena hanya menetapkan semua sampel ke kelas lazim adalah cara mudah untuk mencapai akurasi yang tinggi. Akurasi dibatasi ke  $[0, 1]$ , di mana 1 mewakili memprediksi semua sampel positif dan negatif dengan benar, dan 0 mewakili memprediksi tidak ada sampel positif atau negatif dengan benar.

$$ACC = \frac{\# \text{ Correctly classified samples}}{\# \text{ all samples}} = \frac{TP + TN}{TP + FP + TN + FN} \quad (4)$$

### 2.3.3 Precision

Presisi (PREC). Presisi menunjukkan proporsi sampel yang diambil yang relevan dan relevan dihitung sebagai rasio antara sampel yang diklasifikasikan dengan benar dan semua sampel yang ditugaskan ke kelas itu. Presisi dibatasi ke  $[0, 1]$ , di mana 1 mewakili semua sampel di kelas yang diprediksi dengan benar, dan 0 mewakili tidak ada yang benar prediksi di kelas.

$$PREC = \frac{\# \text{ samples correctly classified}}{\# \text{ samples assigned to class}} = \frac{TC}{TC + FC} \quad (5)$$

### 2.3.4 Recall

Recall (REC). Recall, juga dikenal sebagai sensitivitas atau True Positive Rate (TPR), menunjukkan tingkat positif sampel diklasifikasikan dengan benar, dan dihitung sebagai rasio antara sampel positif yang diklasifikasikan dengan benar dan semuanya sampel ditugaskan ke kelas positif. Penarikan kembali dibatasi ke  $[0, 1]$ , di mana 1 mewakili prediksi sempurna kelas positif, dan 0 mewakili prediksi yang salah dari semua sampel kelas positif. Metrik ini juga dianggap sebagai menjadi salah satu yang paling penting untuk studi medis, karena diinginkan untuk melewati contoh positif sesedikit mungkin, yang berarti recall yang tinggi.

$$REC = \frac{\# \text{ true positive samples}}{\# \text{ samples classified positive}} = \frac{TP}{TP + FN} \quad (6)$$

### 2.3.5 F1-Score

F1 Score (F1). F1 Score adalah rata-rata harmonik dari presisi dan recall, yang berarti bahwa skor tersebut menghukum nilai ekstrem dari keduanya. Metrik ini tidak simetris antar kelas, yaitu bergantung pada kelas mana yang didefinisikan sebagai positif dan negatif. Misalnya, dalam kasus kelas positif yang besar dan pengklasifikasi yang bias terhadap mayoritas ini F1 Score, sebanding dengan TP, akan tinggi. Mendefinisikan ulang label kelas sehingga kelas negatif adalah mayoritas dan pengklasifikasi bias terhadap kelas

negatif akan menghasilkan F1 Score yang rendah, meskipun baik data maupun distribusi kelas relatif tidak berubah. F1 Score terbatas pada  $[0, 1]$ , di mana 1 mewakili nilai presisi dan penarikan maksimum dan 0 mewakili presisi dan/atau penarikan nol.

$$F1 = 2 \times \frac{precision \times recall}{precision + recall} = \frac{2 \times TP}{2 \times TP + FP + FN} \quad (7)$$

## **BAB III METODOLOGI PENELITIAN**

### **3.1 Tujuan Penelitian**

Tujuan dalam penelitian adalah untuk mendapatkan metode data mining terbaik berdasarkan data *Fetal Health Classification*, serta memperoleh tujuan sebagai berikut:

- a. Mengetahui distribusi Kesehatan janin pada data Fetal Health Classification.
- b. Mengetahui hasil analisis Kesehatan janin pada data Fetal Health Classification.
- c. Mengetahui nilai Accuracy, Precision dan Recall pada setiap algoritma data mining.
- d. Mengetahui metode terbaik untuk mendiagnosis Kesehatan janin.

### **3.2 Tempat dan Waktu Penelitian**

Penelitian ini dilaksanakan di Kos. Kos tersebut dipilih karena terdapat fasilitas Wi-Fi dan bisa rebahan. Penelitian ini dimulai September 2023 sampai dengan Oktober 2023. Waktu tersebut dipilih karena tempat penelitian bersedia menerima peneliti dan dianggap waktu yang tepat untuk memulai penelitian.

### **3.3 Populasi dan Teknik Pengambilan Sampel**

#### **3.3.1 Populasi**

Menurut Sugiyono (2014) populasi adalah wilayah generalisasi yang terdiri atas obyek atau subyek yang mempunyai kualitas dan karakteristik tertentu yang ditetapkan oleh peneliti untuk dipelajari dan kemudian ditarik kesimpulan. Populasi bukan hanya orang, tetapi juga obyek dan benda-benda alam yang lain. Untuk menentukan sampel yang akan digunakan dalam penelitian, terdapat berbagai Teknik sampling yang digunakan.

Populasi dalam penelitian ini adalah seluruh pasien *Fetal Health* dengan jumlah 2.126 orang.

#### **3.3.2 Sampel**

Menurut Warwick (1975) Sampel adalah Sebagian dari suatu hal yang luas, yang khusus dipilih untuk mewakili keseluruhan. Dalam penelitian ini peneliti menggunakan *non-probability sampling*. Teknik non probability sampel menurut (Sugiyono, 2015)

Teknik yang tidak memberi peluang/kesempatan yang sama bagi setiap unsur atau anggota populasi untuk dipilih menjadi sampel.

Pengambilan sampel dalam penelitian menggunakan Teknik convenience sampling yaitu menggunakan kelas yang sudah tersedia.

### 3.4 Teknik Pengumpulan Data

Data yang digunakan oleh peneliti adalah data kuantitatif. Menurut Sugiyono data kuantitatif adalah data yang berbentuk angka, atau data kualitatif (skoring). Sedangkan sumber data yang digunakan oleh peneliti adalah dengan menggunakan data sekunder. Data sekunder merupakan sumber data suatu penelitian yang diperoleh peneliti secara tidak langsung melalui media perantara.

Dataset *Fetal Health* ini mempunyai 2.126 data pasien yang diekstrak dari pemeriksaan kardiotokogram (CTG), CTG sendiri bekerja dengan mengirimkan denyut ultrasonic dan membaca responsnya, sehingga menjelaskan denyut jantung janin (FHR), gerakan janin, kontraksi rahim, dan banyak lagi. Dataset tersebut dikategorikan normal, suspect (kemungkinan), dan pathologic (kanker). Berikut credit sumber lengkap dataset *Fetal Health*.

1. Judul: *Fetal Health Classification*
2. Sumber: Ayres de Campos et al. (2000) SisPorto 2.0 A Program for Automated Analysis of Cardiotocograms. J Matern Fetal Med 5:311-318 ([https://onlinelibrary.wiley.com/doi/10.1002/1520-6661\(200009/10\)9:5%3C311::AID-MFM12%3E3.0.CO;2-9](https://onlinelibrary.wiley.com/doi/10.1002/1520-6661(200009/10)9:5%3C311::AID-MFM12%3E3.0.CO;2-9))
3. Download: <https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification>

Berikut table dibawah ini menunjukkan detail dataset yang digunakan dalam eksperimen.

*Tabel 3 Dataset yang digunakan eksperimen*

Dataset	Jumlah Record	Jumlah Atribut	Jumlah Class
Fetal Health	2.126	22	3

## BAB IV HASIL & PEMBAHASAN

### 4.1 Data collection

Pengumpulan data yang digunakan untuk melakukan klasifikasi Kesehatan janin dengan memanfaatkan metode algoritma Naïve Bayes dan Decision Tree diperoleh dari *public dataset* yang terdapat pada situs Kaggle. Dataset tersebut memiliki 2.126 record dengan jumlah 22 kolom sebagai atribut. Berikut ini adalah penjelasan setiap kolom dari data record.

1. **Atribut *baseline\_value*** berisi data denyut jantung janin atau FHR (*Fetal Health Rate*) dengan satuan numerik. FHR pada janin normal umumnya berkisar antara 110 sampai dengan 160. Sedangkan FHR dibawah 110 diklasifikasikan *Fetal Bradycardia*. Jika di atas 160 diklasifikasikan *Fetal Tachcardia* [6]. *Fetal Tachcardia* adalah peningkatan detak jantung janin yang tidak normal. *Fetal Bradycardia* adalah rendahnya detak jantung janin secara tidak normal.
2. **Atribut *accelerations*** berisi data jumlah akselerasi janin per detik dengan satuan numerik. Pada kasus ini, atribut *accelerations* akan dibagi menjadi 2 kategori, antara lain bernilai *True* jika janin melakukan akselerasi lebih dari 0 detik, dan *False* jika janin tidak melakukan akselerasi saat dilakukan *Cardiotocography*.
3. **Atribut *fetal\_movement*** berisi data jumlah Gerakan janin per detik dengan satuan numerik. Pada kasus ini, atribut *fetal\_movement* akan dibagi menjadi 2 kategori, bernilai *True* jika janin melakukan pergerakan lebih dari 0 detik, dan *False* jika janin tidak melakukan pergerakan saat pengujian *Cardiotocography*.
4. **Atribut *uterine\_contractions*** berisi data jumlah kontraksi uterus per detik dengan satuan numerik. Atribut *uterine\_contractions* dibagi menjadi 2 kategori, antara lain bernilai *True* jika terdapat kontraksi *uterine* pada janin lebih dari 0 detik, *False* jika janin tidak terdapat kontraksi *uterine* saat uji *Cardiotocography*.
5. **Atribut *light\_decelerations*** berisi data jumlah LD per detik dengan satuan numerik. Pada atribut dibagi 2 kategori, antara lain bernilai *True* jika terdapat tingkat deselerasi ringan pada janin lebih dari 0 detik, *False* jika janin tidak terdapat tingkat deselerasi ringan saat dilakukan *Cardiotocography*.
6. **Atribut *severe\_decelerations*** berisi data jumlah SD per detik dengan satuan numerik. Atribut terdiri dari 2 kategori, antara lain bernilai *True* jika terdapat



tingkat deselerasi yang berat pada janin lebih dari 0 detik, dan *False* jika janin tidak terdapat tingkat deselerasi yang berat saat dilakukan *Cardiotocography*.

7. **Atribut *prolongued\_decelerations*** berisi data jumlah PD per detik dengan satuan numerik dan dibagi menjadi 2 kategori, bernilai *True* jika terdapat tingkat deselerasi yang berkepanjangan pada janin lebih dari 0 detik, dan *False* jika janin tidak terdapat tingkat deselerasi yang berkepanjangan saat dilakukan *Cardiotocography*.
8. **Atribut *abnormal\_short\_term\_variability*** berisi data persentase waktu dengan variabilitas jangka Panjang yang abnormal dalam satuan numerik.
9. **Atribut *mean\_value\_of\_short\_term\_variability*** berisi data rata-rata variabilitas jangka pendek dalam satuan numerik.
10. **Atribut *percentage\_of\_time\_with\_abnormal\_long\_term\_variability*** berisi data persentase variabilitas jangka Panjang dalam satuan numerik.
11. **Atribut *mean\_value\_of\_long\_term\_variability*** berisi data nilai rata-rata variabilitas jangka Panjang dalam satuan numerik.
12. **Atribut *histogram\_width*** berisi data lebar histogram yang dibuat menggunakan semua nilai dari sebuah record dalam satuan numerik.
13. **Atribut *histogram\_min*** berisi data nilai minimum histogram dalam satuan numerik.
14. **Atribut *histogram\_max*** berisi data nilai maksimum histogram dalam satuan numerik.
15. **Atribut *histogram\_number\_of\_peaks*** berisi tentang data jumlah puncak dalam pengujian histogram dalam satuan numerik.
16. **Atribut *histogram\_number\_of\_zeroes*** berisi tentang data jumlah angka nol dalam pengujian histogram dalam satuan numerik.
17. **Atribut *histogram\_mode*** berisi tentang data mode histogram dalam satuan numerik.
18. **Atribut *histogram\_mean*** berisi tentang data rata-rata histogram dalam satuan numerik.
19. **Atribut *histogram\_median*** berisi tentang data nilai median histogram dalam satuan numerik.









20. **Atribut histogram\_variance** berisi tentang data perbedaan histogram dalam satuan numerik.
21. **Atribut histogram\_tendency** berisi tentang data kecenderungan histogram dalam satuan numerik.
22. **Atribut fetal\_health** berisi tentang data Kesehatan janin dalam satuan numerik.

## **4.2 Data preprocessing**

Public dataset dengan jumlah 22 kolom tersebut hanya mempunyai nilai atribut numerik, sedangkan untuk mengimplementasikan klasifikasi dengan menggunakan algoritma Naïve Bayes dan Decision Tree data atribut numerik harus diubah kedalam sebuah kategori data sehingga data akan menjadi bentuk yang paling sesuai dalam mengimplementasikan algoritma Naïve Bayes dan Decision Tree. Hal tersebut menggunakan Teknik umum pada data *preprocessing* yaitu data transformation.

### **4.2.1 Features Statistic**

Pada tahap pertama preprocessing saya lakukan pengecekan menggunakan widget *Features Statistic* pada Orange data mining untuk melakukan pengecekan nilai Mean, Mode, Median, Min, Max dan apakah terdapat missing value pada dataset Fetal Health ini.

Feature Statistics										Wed Oct 11 23, 19:56:25									
Name	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing											
 baseline value		133.304	133	133	0.0738053	106	160	0 (0 %)											
 accelerations		0.00317827	0.00	0.002	1.21597	0.00	0.019	0 (0 %)											
 fetal_movement		0.00948071	0.00	0.00	4.92103	0.00	0.481	0 (0 %)											
 uterine_contractions		0.00436642	0.00	0.004	0.674552	0.00	0.015	0 (0 %)											
 light_decelerations		0.00188946	0.00	0.00	1.56632	0.00	0.015	0 (0 %)											
 severe_decelerations		3.29257e-06	0.00	0.00	17.3987	0.00	0.001	0 (0 %)											
 prolonged_decelerations		0.000158514	0.00	0.00	3.72087	0.00	0.005	0 (0 %)											
 abnormal_short_term_variability		46.9901	60	49	0.365795	12	87	0 (0 %)											
 mean_value_of_short_term_variability		1.33278	0.8	1.2	0.662548	0.2	7	0 (0 %)											
 percentage_of_time_with_abnormal_long_term_variability		9.84666	0.00	0.00	1.8679	0.00	91	0 (0 %)											
 mean_value_of_long_term_variability		8.18763	0.00	7.4	0.687247	0.00	50.7	0 (0 %)											
 histogram_width		70.4459	39	67.5	0.552857	3	180	0 (0 %)											
 histogram_min		93.5795	50	93	0.315809	50	159	0 (0 %)											
 histogram_max		164.025	157	162	0.109373	122	238	0 (0 %)											
 histogram_number_of_peaks		4.0682	1	3	0.724814	0.00	18	0 (0 %)											
 histogram_number_of_zeroes		0.323612	0.00	0.00	2.18129	0.00	10	0 (0 %)											
 histogram_mode		137.452	133	139	0.11915	60	187	0 (0 %)											
 histogram_mean		134.611	143	136	0.115815	73	182	0 (0 %)											
 histogram_median		138.09	146	139	0.104737	77	186	0 (0 %)											
 histogram_variance		18.8081	1	7	1.54034	0.00	269	0 (0 %)											
 histogram_tendency		0.32032	0.00	0.00	1.90648	-1	1	0 (0 %)											
 fetal_health			1.0		0.675			0 (0 %)											

Gambar 4 Features Statistics

Berdasarkan informasi diatas menunjukkan bahwa tidak terdapat missing value pada setiap fitur yang ada pada dataset *Fetal Health*, sehingga tidak perlu dilakukan preprocessing lanjutan seperti *Impute Missing Value* atau memperbaiki nilai kosong pada setiap fitur.

### 4.2.2 Seleksi Fitur dan target

Pada tahap kedua preprocessing saya lakukan pengecekan melakukan seleksi fitur dan target menggunakan widget *Select Columns* pada Orange data mining untuk menentukan fitur dan target yang akan digunakan nantinya.

Select Columns	Wed Oct 11 23, 20:10:19
<b>Input data</b>	
<b>Features:</b> baseline value, accelerations, fetal_movement, uterine_contractions, light_decelerations, severe_decelerations, prolonged_decelerations, abnormal_short_term_variability, mean_value_of_short_term_variability, percentage_of_time_with_abnormal_long_term_variability, mean_value_of_long_term_variability, histogram_width, histogram_min, histogram_max, histogram_number_of_peaks, histogram_number_of_zeroes, histogram_mode, histogram_mean, histogram_median, histogram_variance, histogram_tendency, fetal_health (total: 22 features)	
<b>Output data</b>	
<b>Features:</b> baseline value, accelerations, fetal_movement, uterine_contractions, light_decelerations, severe_decelerations, prolonged_decelerations, abnormal_short_term_variability, mean_value_of_short_term_variability, percentage_of_time_with_abnormal_long_term_variability, mean_value_of_long_term_variability, histogram_width, histogram_min, histogram_max, histogram_number_of_peaks, histogram_number_of_zeroes, histogram_mode, histogram_mean, histogram_median, histogram_variance, histogram_tendency (total: 21 features)	
<b>Target:</b> fetal_health	

*Gambar 5 Seleksi Fitur*

Berdasarkan informasi diatas menunjukkan bahwa saya memilih 21 atribut untuk dijadikan fitur dan 1 atribut menjadi target. Fitur yang akan saya gunakan diantaranya *Baseline value, Accelerations, Fetal movement, Uterine contractions, Light decelarations, Severe decelerations, Prolonged decelerations, Abnormal short term variability, Mean value of short term variability, Percentage of time width abnormal long term variability, Mean value of long term variability, Histogram width, Histogram min, Histogram max, Histogram number of peaks, Histogram number of zeroes, Histogram mode, Histogram mean, Histogram median, Histogram variance, Histogram tendency* dan target yang saya gunakan adalah *Fetal health*.

### 4.2.3 Edit Domain

Pada tahap ketiga preprocessing saya lakukan pengeditan domain atau penamaan record menggunakan widget *Edit Domain* pada Orange data mining untuk memudahkan membaca target nantinya.

- **fetal\_health**  
Values:
  - 1.0 → Normal
  - 2.0 → Suspect
  - 3.0 → Pathological

*Gambar 6 Edit Domain*

Berdasarkan informasi diatas menunjukkan bahwa saya mengedit record pada atribut *fetal\_health*. Saya menginisialisasi nilai 1 sebagai kelas Normal, nilai 2 sebagai kelas Suspect dan nilai 3 sebagai kelas Pathological.

### 4.3 Splitting data


Penggunaan public dataset yang akan diteliti sebanyak 2.126 data terdiri dari 1.655 data kelas yang bernilai Normal, 295 data kelas yang bernilai Suspect, dan 176 data kelas yang bernilai Pathological. Public dataset akan diuji sebanyak 4 kali percobaan yaitu 60%, 70%, 80%, dan 90% data training, sedangkan 40%, 30%, 20%, dan 10% data testing.

#### 4.3.1 Splitting data training 60% dan testing 40%

**Sampling type:** Random sample with 60 % of data, deterministic  
**Input:** 2126 instances  
**Sample:** 1276 instances  
**Remaining:** 850 instances

*Gambar 7 Splitting data training 60% dan testing 40%*


Berdasarkan Gambar 7, Hasil sampling sebesar 60% pada data training dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 1.276 data dari 2.126 dataset.



*Gambar 8 Distribusi Data Training 60%*

Pada Gambar 8 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 980 data, total kelas suspect sebanyak 195 data, dan total kelas pathological sebanyak 101 data dari sampel training sebesar 1.276 data.


Sedangkan hasil sampling sebesar 40% pada data testing dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 850 data dari 2.126 dataset.



*Gambar 9 Distribusi Data Testing 40%*

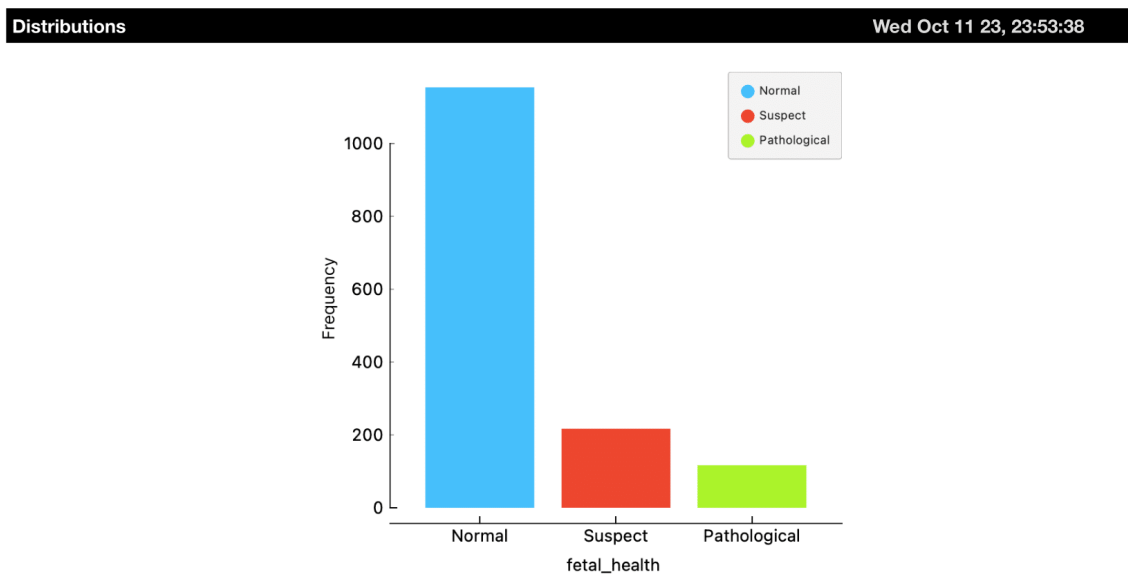
Pada Gambar 9 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 675 data, total kelas suspect sebanyak 100 data, dan total kelas pathological sebanyak 75 data dari sampel testing sebesar 850 data.

#### 4.3.2 Splitting data training 70% dan testing 30%



*Gambar 10 Splitting data training 70% dan testing 30%*


Berdasarkan Gambar 10, Hasil sampling sebesar 70% pada data training dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 1.489 data dari 2.126 dataset.



*Gambar 11 Distribusi Data Training 70%*

Pada Gambar 11 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 1.155 data, total kelas suspect sebanyak 217 data, dan total kelas pathological sebanyak 117 data dari sampel training sebesar 1.489 data.

Sedangkan hasil sampling sebesar 30% pada data testing dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 637 data dari 2.126 dataset.



*Gambar 12 Distribusi Data Testing 30%*

Pada Gambar 12 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 500 data, total kelas suspect sebanyak 78 data, dan total kelas pathological sebanyak 59 data dari sampel testing sebesar 637 data.

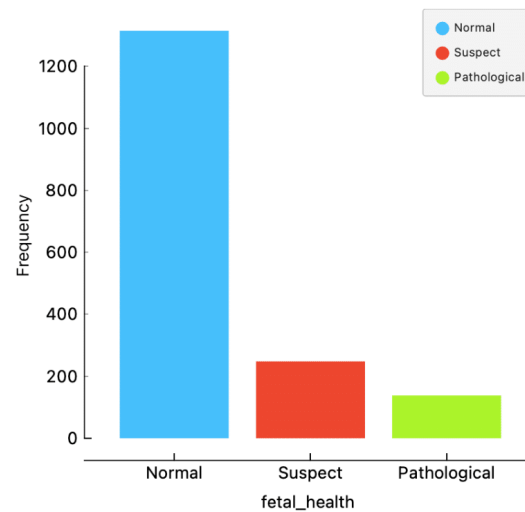
#### 4.3.3 Splitting data training 80% dan testing 20%

**Sampling type:** Random sample with 80 % of data, deterministic  
**Input:** 2126 instances  
**Sample:** 1701 instances  
**Remaining:** 425 instances

*Gambar 13 Splitting data training 80% dan testing 20%*

Berdasarkan Gambar 13, Hasil sampling sebesar 80% pada data training dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 1.701 data dari 2.126 dataset.






*Gambar 14 Distribusi Data Training 80%*

Pada Gambar 14 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 1.315 data, total kelas suspect sebanyak 248 data, dan total kelas pathological sebanyak 138 data dari sampel training sebesar 1.701 data.


Sedangkan hasil sampling sebesar 20% pada data testing dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 425 data dari 2.126 dataset.



*Gambar 15 Distribusi Data Testing 20%*


Pada Gambar 15 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 340 data, total kelas suspect sebanyak 47 data, dan total kelas pathological sebanyak 38 data dari sampel testing sebesar 425 data.

#### 4.3.4 Splitting data training 90% dan testing 10%



*Gambar 16 Splitting data training 90% dan testing 10%*

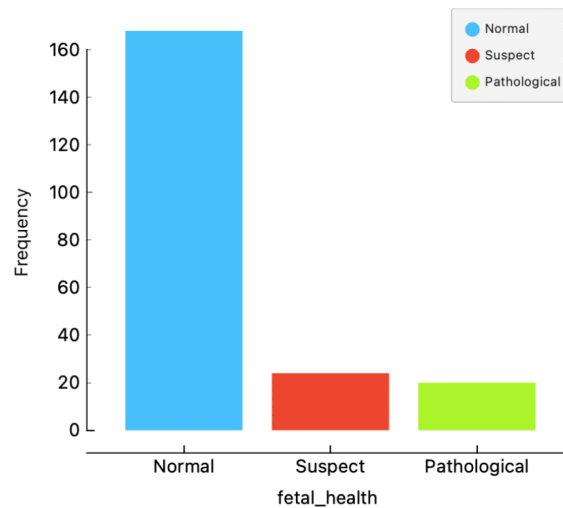
Berdasarkan Gambar 16, Hasil sampling sebesar 90% pada data training dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 1.914 data dari 2.126 dataset.



*Gambar 17 Distribusi Data Training 90%*

Pada Gambar 17 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 1.487 data, total kelas suspect sebanyak 271 data, dan total kelas pathological sebanyak 156 data dari sampel training sebesar 1.914 data.

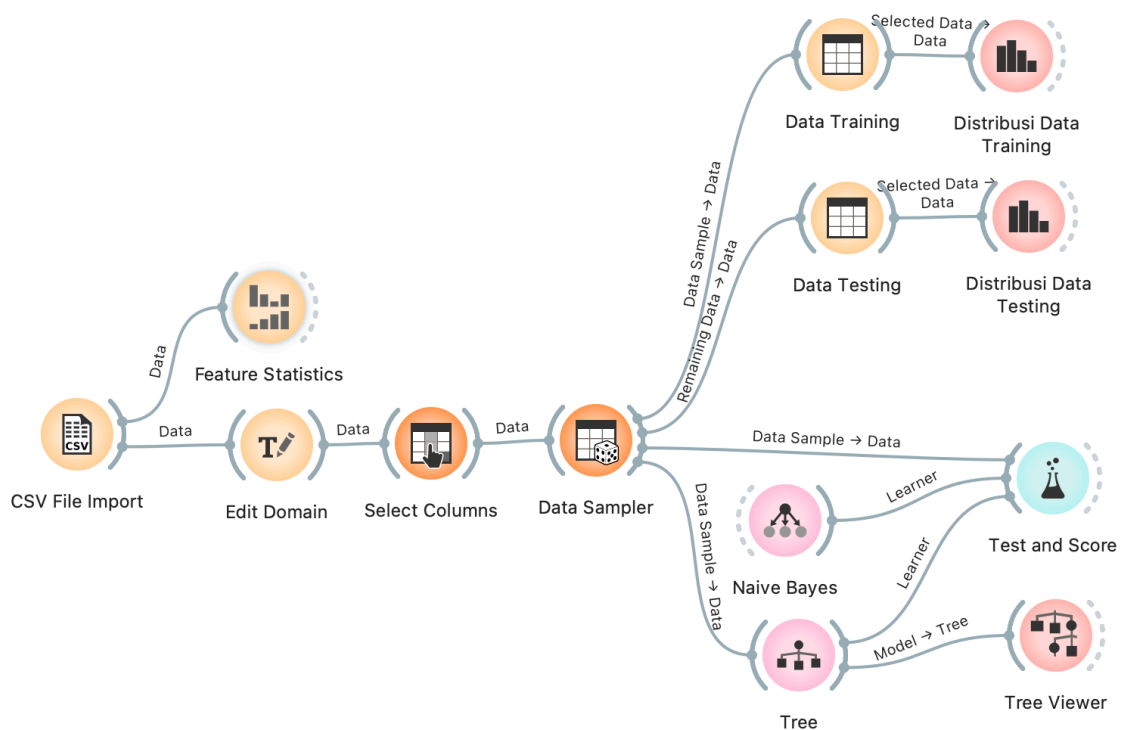
Sedangkan hasil sampling sebesar 10% pada data testing dengan widget *Data Sampler* dengan tipe sampling *fixed proportion of data* menghasilkan 212 data dari 2.126 dataset.



Gambar 18 Distribusi Data Testing 10%

Pada Gambar 18 menunjukkan hasil dari total kelas yang bernilai normal sebanyak 168 data, total kelas suspect sebanyak 24 data, dan total kelas pathological sebanyak 20 data dari sampel testing sebesar 212 data.

#### 4.4 Penerapan Algoritma Naïve Bayes dan Decision Tree



Gambar 19 Algoritma Naive Bayes dan Decision Tree

Pada pengujian dataset dilakukan dengan menggunakan Algoritma Naïve Bayes dan Decision Tree. Dengan menampilkan nilai *Accuracy*, *Precision*, *Recall*, dan *F1 Score* dari beberapa splitting yang sudah dibuat sebelumnya.

1. Split data train 60% dan test 40%
  - a. 2 Fold Cross validation

Test and Score							Wed Oct 11 23:
Settings							
Sampling type: 2-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.905	0.783	0.802	0.847	0.783	0.557	
Tree	0.834	0.909	0.906	0.906	0.909	0.751	

*Gambar 20 2 Fold Cross validation 60%*

Pada Gambar 20 menunjukkan hasil dari *Test and Score* 2 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.5%, *Precision* 84.7%, *Recall* 78.3%, dan *F1-Score* 80.2%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 83.4%, *Precision* 90.6%, *Recall* 90.9%, dan *F1-Score* 90.6%.

- b. 3 Fold Cross validation

Test and Score							Wed Oct 11 23:
Settings							
Sampling type: 3-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.901	0.778	0.798	0.846	0.778	0.553	
Tree	0.849	0.898	0.897	0.896	0.898	0.728	

*Gambar 21 3 Fold Cross validation 60%*

Pada Gambar 21 menunjukkan hasil dari *Test and Score* 3 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.1%, *Precision* 84.6%, *Recall* 77.8%, dan *F1-Score* 79.8%. Sedangkan pada

algoritma Decision Tree mendapatkan nilai *Accuracy* 84.9%, *Precision* 89.6%, *Recall* 89.8%, dan *F1-Score* 89.7%.

c. 5 Fold Cross validation

Test and Score							Wed Oct 11 23,
Settings							
Sampling type: 5-fold Cross validation Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.906	0.781	0.800	0.847	0.781	0.558	
Tree	0.907	0.928	0.926	0.926	0.928	0.806	

*Gambar 22 5 Fold Cross validation 60%*

Pada Gambar 22 menunjukkan hasil dari *Test and Score* 5 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.6%, *Precision* 84.7%, *Recall* 78.1%, dan *F1-Score* 80%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 90.7%, *Precision* 92.6%, *Recall* 92.8%, dan *F1-Score* 92.6%.

d. 10 Fold Cross validation

Test and Score							Wed Oct 11 23,
Settings							
Sampling type: 10-fold Cross validation Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.906	0.783	0.802	0.848	0.783	0.559	
Tree	0.879	0.928	0.926	0.926	0.928	0.806	

*Gambar 23 10 Fold Cross validation 60%*

Pada Gambar 23 menunjukkan hasil dari *Test and Score* 10 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.6%, *Precision* 84.8%, *Recall* 78.3%, dan *F1-Score* 80.2%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 87.9%, *Precision* 92.6%, *Recall* 92.8%, dan *F1-Score* 92.6%.

Berdasarkan Split data train 60% dan test 40% dengan 4 fold (2, 3, 5, 10) didapatkan hasil *Accuracy* tertinggi pada Fold 5 pada masing-masing algoritma.

2. Split data train 70% dan test 30%
  - a. 2 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 2-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.904	0.788	0.807	0.853	0.788	0.562	
Tree	0.857	0.910	0.909	0.909	0.910	0.752	

*Gambar 24 2 Fold Cross validation 70%*

Pada Gambar 24 menunjukkan hasil dari *Test and Score* 2 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.4%, *Precision* 85.3%, *Recall* 78.8%, dan *F1-Score* 80.7%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 85.7%, *Precision* 90.9%, *Recall* 91%, dan *F1-Score* 90.9%.

- b. 3 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 3-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.908	0.786	0.806	0.854	0.786	0.562	
Tree	0.860	0.919	0.917	0.916	0.919	0.773	

*Gambar 25 3 Fold Cross validation 70%*

Pada Gambar 25 menunjukkan hasil dari *Test and Score* 3 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.8%, *Precision* 85.4%, *Recall* 78.6%, dan *F1-Score* 80.6%. Sedangkan pada

algoritma Decision Tree mendapatkan nilai *Accuracy* 86%, *Precision* 91.6%, *Recall* 91.9%, dan *F1-Score* 91.7%.

c. 5 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 5-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.909	0.790	0.810	0.857	0.790	0.570	
Tree	0.864	0.916	0.913	0.913	0.916	0.765	

*Gambar 26 5 Fold Cross validation 70%*

Pada Gambar 26 menunjukkan hasil dari *Test and Score* 5 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.9%, *Precision* 85.7%, *Recall* 79%, dan *F1-Score* 81%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 91.6%, *Precision* 91.3%, *Recall* 91.6%, dan *F1-Score* 91.3%.

d. 10 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 10-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.910	0.787	0.807	0.854	0.787	0.561	
Tree	0.905	0.929	0.927	0.926	0.929	0.802	

*Gambar 27 10 Fold Cross validation 70%*

Pada Gambar 27 menunjukkan hasil dari *Test and Score* 10 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 91%, *Precision* 85.4%, *Recall* 78.7%, dan *F1-Score* 80.7%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 90.5%, *Precision* 92.6%, *Recall* 92.9%, dan *F1-Score* 92.7%.

Berdasarkan Split data train 70% dan test 30% dengan 4 fold (2, 3, 5, 10) didapatkan hasil *Accuracy* tertinggi pada Fold 10 pada masing-masing algoritma.

3. Split data train 80% dan test 20%

a. 2 Fold Cross validation

Test and Score							Thu Oct 12 23, 0
Settings							
Sampling type: 2-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.907	0.789	0.808	0.852	0.789	0.564	
Tree	0.862	0.899	0.898	0.897	0.899	0.724	

*Gambar 28 2 Fold Cross validation 80%*

Pada Gambar 28 menunjukkan hasil dari *Test and Score* 2 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.7%, *Precision* 85.2%, *Recall* 78.9%, dan *F1-Score* 80.8%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 86.2%, *Precision* 89.7%, *Recall* 89.9%, dan *F1-Score* 89.8%.

b. 3 Fold Cross validation

Test and Score							Thu Oct 12 23, 0
Settings							
Sampling type: 3-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.905	0.787	0.806	0.850	0.787	0.559	
Tree	0.852	0.910	0.908	0.907	0.910	0.750	

*Gambar 29 3 Fold Cross validation 80%*

Pada Gambar 29 menunjukkan hasil dari *Test and Score* 3 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.5%, *Precision* 85%, *Recall* 78.7%, dan *F1-Score* 80.6%. Sedangkan pada



algoritma Decision Tree mendapatkan nilai *Accuracy* 85.2%, *Precision* 90.7%, *Recall* 91%, dan *F1-Score* 90.8%.

c. 5 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 5-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.907	0.785	0.804	0.848	0.785	0.554	
Tree	0.871	0.915	0.914	0.915	0.915	0.767	

*Gambar 30 5 Fold Cross validation 80%*

Pada Gambar 30 menunjukkan hasil dari *Test and Score* 5 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.7%, *Precision* 84.8%, *Recall* 78.5%, dan *F1-Score* 80.4%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 87.1%, *Precision* 91.5%, *Recall* 91.5%, dan *F1-Score* 91.4%.

d. 10 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 10-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.909	0.787	0.806	0.849	0.787	0.557	
Tree	0.865	0.922	0.921	0.921	0.922	0.786	

*Gambar 31 10 Fold Cross validation 80%*

Pada Gambar 31 menunjukkan hasil dari *Test and Score* 10 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.9%, *Precision* 84.9%, *Recall* 78.7%, dan *F1-Score* 80.6%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 86.5%, *Precision* 92.1%, *Recall* 92.2%, dan *F1-Score* 92.1%.

Berdasarkan Split data train 80% dan test 20% dengan 4 fold (2, 3, 5, 10) didapatkan hasil *Accuracy* tertinggi pada Fold 10 untuk algoritma Naïve Bayes dan Fold 5 untuk algoritma Decision Tree.

4. Split data train 90% dan test 10%
  - a. 2 Fold Cross validation

Test and Score							Thu Oct 12 23, 0
<b>Settings</b>							
Sampling type: 2-fold Cross validation							
Target class: None, show average over classes							
<b>Scores</b>							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.907	0.792	0.810	0.855	0.792	0.565	
Tree	0.856	0.912	0.910	0.910	0.912	0.756	

*Gambar 32 2 Fold Cross validation 90%*

Pada Gambar 32 menunjukkan hasil dari *Test and Score* 2 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.7%, *Precision* 85.5%, *Recall* 79.2%, dan *F1-Score* 81%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 85.6%, *Precision* 91%, *Recall* 91.2%, dan *F1-Score* 91%.

- b. 3 Fold Cross validation

Test and Score							Thu Oct 12 23, 0
<b>Settings</b>							
Sampling type: 3-fold Cross validation							
Target class: None, show average over classes							
<b>Scores</b>							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.904	0.784	0.803	0.848	0.784	0.549	
Tree	0.863	0.921	0.918	0.918	0.921	0.777	

*Gambar 33 3 Fold Cross validation 90%*

Pada Gambar 33 menunjukkan hasil dari *Test and Score* 3 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.4%, *Precision* 84.8%, *Recall* 78.4%, dan *F1-Score* 80.3%. Sedangkan pada

algoritma Decision Tree mendapatkan nilai *Accuracy* 86.3%, *Precision* 91.8%, *Recall* 92.1%, dan *F1-Score* 91.8%.

c. 5 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 5-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.908	0.794	0.812	0.854	0.794	0.565	
Tree	0.864	0.919	0.917	0.917	0.919	0.775	

*Gambar 34 5 Fold Cross validation 90%*

Pada Gambar 34 menunjukkan hasil dari *Test and Score* 5 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.8%, *Precision* 85.4%, *Recall* 79.4%, dan *F1-Score* 81.2%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 86.4%, *Precision* 91.7%, *Recall* 91.9%, dan *F1-Score* 91.7%.

d. 10 Fold Cross validation

Test and Score							Thu Oct 12 23,
Settings							
Sampling type: 10-fold Cross validation							
Target class: None, show average over classes							
Scores							
Model	AUC	CA	F1	Prec	Recall	MCC	
Naive Bayes	0.909	0.789	0.808	0.851	0.789	0.558	
Tree	0.899	0.932	0.930	0.930	0.932	0.810	

*Gambar 35 10 Fold Cross validation 90%*

Pada Gambar 35 menunjukkan hasil dari *Test and Score* 10 Fold Cross validation didapatkan pada algoritma Naïve Bayes dengan *Accuracy* 90.9%, *Precision* 85.1%, *Recall* 78.9%, dan *F1-Score* 80.8%. Sedangkan pada algoritma Decision Tree mendapatkan nilai *Accuracy* 89.9%, *Precision* 93%, *Recall* 93.2%, dan *F1-Score* 93%.

Berdasarkan Split data train 90% dan test 10% dengan 4 fold (2, 3, 5, 10) didapatkan hasil *Accuracy* tertinggi pada Fold 10 pada masing-masing algoritma.

#### 4.5 Evaluasi data dengan Confussion Matrix

Setelah dilakukan implementasi algoritma Naïve Bayes dan Decision Tree didapatkan hasil sebagai berikut:

*Tabel 4 Perbandingan Algoritma*

Training Data	Testing Data	Akurasi Naïve Bayes				Akurasi Decision Tree			
		2 Fold	3 Fold	5 Fold	10 Fold	2 Fold	3 Fold	5 Fold	10 Fold
90%	10%	90.7%	90.4%	90.8%	90.9%	85.6%	86.3%	86.4%	89.9%
80%	20%	90.7%	90.5%	90.7%	90.9%	86.2%	85.2%	87.1%	86.5%
70%	30%	90.4%	90.8%	90.9%	91%	85.7%	86%	86.4%	90.5%
60%	40%	90.5%	90.1%	90.6%	90.6%	83.4%	84.9%	90.7%	87.9%

Berdasarkan informasi pada Tabel 4, akurasi tertinggi berada pada splitting dengan Data Train 70% dan Data Test 30% dengan 10 Fold. Dimana disebutkan bahwa data *Testing* yang berjumlah 637 data dengan perincian data kelas normal sebanyak 500 data, total kelas suspect sebanyak 78 data, dan total kelas pathological sebanyak 59 data. Keseluruhan dari 637 data diperoleh dari total 2.126 data yang diantaranya terdiri dari 1.655 data kelas yang bernilai normal, 295 data kelas yang bernilai suspect, dan 176 data kelas bernilai pathological yang sudah di split menggunakan rasio 70% data training dan 30% data testing.

Berdasarkan pengolahan data rasio 70% untuk data training dan 30% data testing, maka hasil dibutuhkan suatu metode *confusion matrix* untuk menghitung dan mendapatkan nilai akurasi dari algoritma Naïve Bayes dan Decision Tree. Hasil *confusion matrix* dapat dilihat pada Tabel Confusion Matrix.

Tabel 5 Confusion Matrix

Confusion Matrix Naïve Bayes						Confusion Matrix Decision Tree					
Confusion Matrix						Confusion Matrix					
Confusion matrix for Naive Bayes (showing number of instances)						Confusion matrix for Tree (showing number of instances)					
Actual		Predicted			Σ	Actual		Predicted			Σ
		Normal	Suspect	Pathological				Normal	Suspect	Pathological	
Actual	Normal	920	147	88	1.155	Actual	Normal	1121	28	6	1.155
	Suspect	28	173	16	217		Suspect	60	154	3	217
	Pathological	6	32	79	117		Pathological	8	1	108	117
Σ		954	352	183	1.489	Σ		1.189	183	117	1.489

Berdasarkan Tabel 5 diatas, maka akurasi dapat dihitung dengan persamaan 4 yang telah dibahas diatas, nilai dari persamaan tersebut dilihat dibawah ini.

$$Acc\ Naive\ Bayes = \frac{920 + 173 + 79}{920 + 173 + 79 + 28 + 147 + 32 + 16} = 0.8401433692 = 84\%$$

$$Acc\ Decision\ Tree = \frac{1121 + 154 + 108}{1121 + 154 + 108 + 60 + 28 + 1 + 3} = 0.9376271186$$

$$= 93.76\%$$

Pengujian dataset pada penelitian ini, menggunakan data sekunder sebanyak 2.126 dataset berasal dari Kaggle, dimana atribut berjumlah 22, dan terdapat 3 kelas yang diklasifikasi adalah normal, suspect, dan pathological.

Hasil dari evaluasi dengan variasi *training* dan *testing* data, dimana variasi splitting data dapat dilihat pada Tabel 6.

Tabel 6 Hasil Perbandingan Evaluasi

Training Data	Testing Data	Akurasi Naïve Bayes	Akurasi Decision Tree
90%	10%	90.9%	89.9%
80%	20%	90.9%	86.5%
70%	30%	91%	90.5%
60%	40%	90.6%	87.9%

Berdasarkan Tabel 6, maka pengujian dilakukan untuk data training terdiri dari 60%, 70%, 80%, dan 90%, sedangkan data testing terdiri dari 40%, 30%, 20%, 10%. Hasil pengujian untuk 90% data training dan 10% data testing mendapatkan akurasi sebesar 90.9% pada algoritma Naïve Bayes dan 89.9% pada algoritma Decision Tree. Hasil pengujian untuk 80% data training dan 20% data testing mendapatkan akurasi sebesar 90.9% pada algoritma Naïve Bayes dan 86.5% pada algoritma Decision Tree. Hasil pengujian untuk 70% data training dan 30% data testing mendapatkan akurasi sebesar 91% pada algoritma Naïve Bayes dan 90.5% pada algoritma Decision Tree. Hasil pengujian untuk 60% data training dan 40% data testing mendapatkan akurasi sebesar 90.6% pada algoritma Naïve Bayes dan 87.9% pada algoritma Decision Tree.

## **BAB V PENUTUP**

### **5.1 Kesimpulan**

Dari hasil analisis diatas dapat disimpulkan bahwa performa algoritma Naïve Bayes cenderung lebih baik daripada algoritma Decision Tree dalam konteks pengujian dengan variasi data training dan data testing. Akurasi Naïve Bayes stabil diatas 90% pada semua percobaan, dengan tingkat tertinggi mencapai 91%. Sementara itu, algoritma Decision Tree, meskipun memiliki kinerja yang baik dengan akurasi yang sedikit lebih rendah berkisar antara 86.5% hingga 90.5%. Oleh karena itu, dalam kasus Fetal Health, algoritma Naïve Bayes merupakan pilihan yang tepat untuk klasifikasi Kesehatan janin.

### **5.2 Saran**

## DAFTAR PUSTAKA

- [1] V. Yazia and U. Suryani, “Faktor Yang Berhubungan Dengan Tingkat Stres Pada Ibu Hamil Dalam Menghadapi Persalinan,” *Jurnal Keperawatan Jiwa (JKJ): Persatuan Perawat Nasional Indonesia*, vol. 10, no. 4, pp. 837–856, 2022.
- [2] M. Rian Santoso and P. Musa, “Rekomendasi Kesehatan Janin Dengan Penerapan Algoritma C5.0 Menggunakan Classifying Cardiotocography Dataset,” *Jurnal SimanteC*, vol. 9, no. 2, 2021.
- [3] L. B.N., T. s Indumathi, and N. Ravi, “A comparative study of classification algorithms for risk prediction in pregnancy,” Oct. 2015, pp. 1–6. doi: 10.1109/TENCON.2015.7373161.
- [4] I. Sulihati, A. Syukur, and A. Marjuni, “Deteksi Kesehatan Janin Menggunakan Decision Tree dan Feature Forward Selection,” *Building of Informatics, Technology and Science (BITS)*, vol. 4, no. 3, Dec. 2022, doi: 10.47065/bits.v4i3.2672.
- [5] ALODOKTER, “Kapan Ibu Hamil Perlu Melakukan Cardiotocography?,” <https://www.alodokter.com/kapan-ibu-hamil-perlu-melakukan-cardiotocography-CTG>.
- [6] K. Madadipouya, “Advanced Computational Intelligence,” *An International Journal (ACII)*, vol. 2, no. 3, 2015, doi: 10.5121/acii.2015.2304.
- [7] M. Aziz Muslim *et al.*, *Data Mining Algoritma C4.5 Disertai Contoh Kasus Dan Penerapannya Dengan Program Komputer*. 2019.
- [8] F. A. Hermawati, *Data Mining*. 2013. [Online]. Available: <https://www.researchgate.net/publication/317692865>
- [9] S. E. , M. P. Prof. Dr. Wibowo, *MANAJEMEN KINERJA*. RAJAWALI PERS, 2009.